PROJEKT - OPIS

Projekt dotyczy analizy genomowej bakterii MRSA (Staphylococcus aureus oporny na metycylinę) pochodzących z ogniska epidemicznego na oddziale noworodkowym. W analizie uwzględniono:

- izolat pobrany od pacjenta będącego źródłem zakażenia (index case, ERR103401),
- izolat od pacjenta z ogniska epidemicznego (outbreak, ERR103400) oraz
- izolat od nosiciela MRSA niezwiązanego z ogniskiem epidemicznym (carriage, ERR103404).

Takie podejście umożliwia ocenę zmienności genetycznej bakterii MRSA w obrębie ogniska epidemicznego oraz poza nim.

Po pobraniu sekwencji z bazy SRA próbki zostały nazwane zgodnie z ich rolą w badanym ognisku epidemicznym (index case, outbreak, carriage), co ułatwi poźniejszą interpretację wyników.

1. Na podstawie przeprowadzonej kontroli jakości można stwierdzić że:

- odczyty charakteryzują się ogólnie dobrą jakością na większości długości sekwencji, choć w części próbek widoczne są spadki jakości na końcach odczytów
- odczyty są gorszej jakości od strony reverse
- długość sekwencji jest jednolita i wynosi ok. 150 bp
- rozkład zawartości GC jest stabilny i odpowiada typowym wartościom dla bakterii Staphylococcus aureus.
- we wszystkich próbkach wykryto obecność adapterów

2. Przeprowadzono usuwanie sekwencji adapterowych przy użyciu programu Trimmomatic (ILLUMINACLIP). Porównanie statystyk przed i po analizie wykazało niewielką redukcję liczby odczytów, co sugeruje ograniczoną obecność adapterów w danych.

Po usunięciu sekwencji adapterowych przeprowadzono ponowną analizę jakości odczytów. Zaobserwowano częściową redukcję zawartości adapterów, jednak nadal są one obecne. Jakość sekwencji (Per base sequence quality) pozostała na podobnym poziomie (poprawa tylko w jednej próbce), z widocznymi spadkami jakości w części odczytów, szczególnie w końcowych fragmentach. Rozkład zawartości GC oraz długość odczytów nie uległy istotnym zmianom.

Wyniki wskazują na konieczność dalszego przycinania sekwencji pod względem jakości.

3. Następnie przeprowadzono przycinanie sekwencji niskiej jakości (LEADING:20, TRAILING:20, SLIDINGWINDOW:5:20, MINLEN:50). Analiza FastQC po przycinaniu wykazała poprawę jakości odczytów oraz usunięcie fragmentów o niskiej wiarygodności.

-----> Ze względu na niepełne usunięcie adapterów w pierwszym etapie (zastosowanie nieoptymalnego zestawu adapterów), przeprowadzono dodatkowe oczyszczanie danych z wykorzystaniem adapterów Nextera. Pozwoliło to na skuteczniejsze usunięcie pozostałości adapterów i poprawę jakości danych przed dalszą analizą. Wszystkie raporty multiqc (1-4) znajddują się w folderze wynikowym projektu w formacie html.

4. Mapowanie odczytów przeprowadzono przy użyciu BWA-MEM, który jest odpowiedni dla danych typu paired-end o długości ~150 bp. Sekwencje zostały zmapowane do genomu referencyjnego *Staphylococcus aureus* (NC_007795.1). Statystyki mapowania (samtools flagstat) wskazują na wysoki odsetek zmapowanych odczytów (>80%), co świadczy o dobrej jakości danych oraz odpowiednim doborze genomu referencyjnego (pliki *stats.txt).

5. Wizualizację zmapowanych odczytów przeprowadzono w programie IGV dla wybranego regionu genomu referencyjnego *Staphylococcus aureus*. Załadowano próbki w formacie bam.

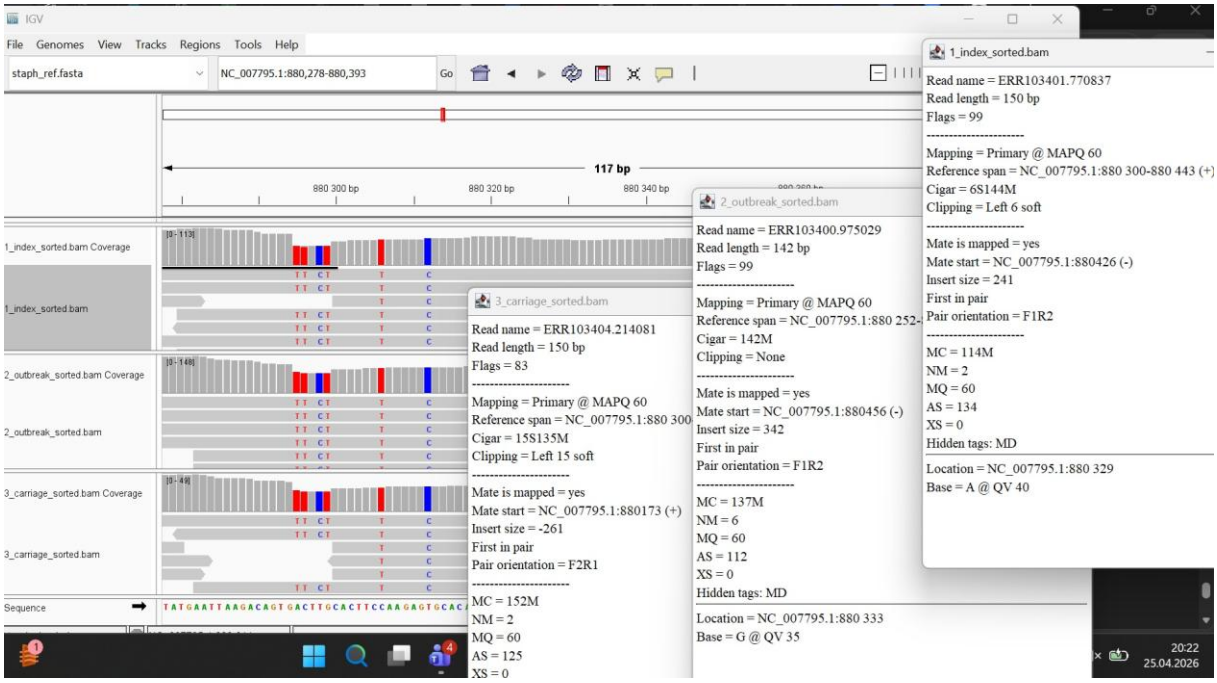

Zaobserwowano wysokie i równomierne pokrycie sekwencji dla wszystkich analizowanych próbek. Większość odczytów charakteryzuje się wysoką jakością mapowania (MAPQ = 60), co wskazuje na jednoznaczne dopasowanie do genomu referencyjnego. W analizowanym regionie widoczne są liczne różnice nukleotydowe (SNP), które występują konsekwentnie w wielu odczytach, sugerując ich rzeczywiste, biologiczne pochodzenie. Dodatkowo zaobserwowano niewielką liczbę niedopasowań (NM), co potwierdza wysoką jakość mapowania.

6. Duplikaty zostały oznaczone i usunięte przy użyciu narzędzi z pakietu Samtools. W pierwszym kroku odczyty zostały posortowane według nazw (queryname), co umożliwiło poprawne sparowanie par odczytów. Następnie zastosowano polecenie samtools fixmate w celu uzupełnienia informacji o parach odczytów. Po ponownym sortowaniu według pozycji genomowej przeprowadzono identyfikację oraz usunięcie duplikatów przy użyciu samtools markdup. Proces ten pozwolił na eliminację artefaktów powstałych podczas amplifikacji PCR, co zwiększa wiarygodność dalszej analizy wariantów genetycznych.

7. Analiza wariantów została przeprowadzona przy użyciu narzędzi z pakietu Samtools/bcftools. Na podstawie zmapowanych odczytów (plików BAM) wygenerowano pliki VCF zawierające zidentyfikowane warianty genetyczne. W analizie wykryto głównie zmiany typu SNP, stanowiące zdecydowaną większość wszystkich wariantów, przy niewielkim udziale insercji i delecji. Łączna liczba wariantów wynosiła około 35–36 tysięcy w zależności od próbki, co wskazuje na znaczną zmienność względem genomu referencyjnego.

8. Warianty zostały przefiltrowane na podstawie jakości (QUAL > 30) oraz głębokości pokrycia (DP > 10), co pozwoliło na usunięcie potencjalnych artefaktów sekwencjonowania. Po filtracji liczba wariantów uległa redukcji, pozostawiając zestaw zmian o wysokiej wiarygodności.

```
(bcftools_env) aleksandraob@Lolla:/mnt/c/Users/ASUS/bioinfo_NGS/pd5201_project$ for sample in 1_index 2_outbreak 3_carriage
do
  echo ">>> $sample BEFORE"
  grep -v "^#" mapping/${sample}.vcf | wc -l

  echo ">>> $sample AFTER"
  grep -v "^#" mapping/${sample}_filtered.vcf | wc -l
done
>>> 1_index BEFORE
38124
>>> 1_index AFTER
36323
>>> 2_outbreak BEFORE
37855
>>> 2_outbreak AFTER
36233
>>> 3_carriage BEFORE
37810
>>> 3_carriage AFTER
34796
```

9. Próba adnotacji wariantów przy użyciu narzędzia SnpEff wykazała ograniczenia wynikające z niedopasowania referencji genomowej do dostępnej bazy danych. W związku z tym szczegółowa adnotacja genowa nie była możliwa.

Na podstawie analizy wariantów stwierdzono jednak, że większość zmian stanowią warianty typu SNP, które mogą wpływać na funkcjonowanie genów bakterii, w tym potencjalnie na mechanizmy oporności na antybiotyki.

Analiza wariantów wykazała, że we wszystkich próbkach dominują zmiany typu SNP, stanowiące ponad 99% wszystkich wariantów. Liczba wariantów była zbliżona pomiędzy próbkami „index” i „outbreak”, natomiast próbka „carriage” charakteryzowała się nieco mniejszą liczbą wariantów. Również pod względem liczby konkretnych zmian nukleotydowych oraz liczby transwersji i tranzycji próbka carriage bardziej odbiegała od dwóch pozostałych (pełne raporty załączone w html:

1. INDEX

Number variants by type

Type	Total
SNP	36,133
MNP	0
INS	94
DEL	96
MIXED	0
INV	0
DUP	0
CNV	0
BND	0
INTERVAL	0
Total	36,323

Base changes (SNPs)

	A	C	G	T
A	0	1,380	5,606	3,356
C	1,294	0	468	5,791
G	5,608	513	0	1,379
T	3,457	5,858	1,423	0

Ts/Tv (transitions / transversions)

Transitions	22,863
Transversions	13,270
Ts/Tv ratio	1.7229

2. OUTBREAK

Number variants by type

Type	Total
SNP	36,033
MNP	0
INS	106
DEL	94
MIXED	0
INV	0
DUP	0
CNV	0
BND	0
INTERVAL	0
Total	36,233

Base changes (SNPs)

	A	C	G	T
A	0	1,399	5,572	3,363
C	1,295	0	463	5,771
G	5,555	517	0	1,372
T	3,451	5,845	1,430	0

Ts/Tv (transitions / transversions)

Transitions	22,743
Transversions	13,290
Ts/Tv ratio	1.7113

3. CARRIAGE

Number variants by type

Type	Total
SNP	34,594
MNP	0
INS	100
DEL	102
MIXED	0
INV	0
DUP	0
CNV	0
BND	0
INTERVAL	0
Total	34,796

Base changes (SNPs)

	A	C	G	T
A	0	1,317	5,371	3,196
C	1,233	0	443	5,598
G	5,397	488	0	1,324
T	3,278	5,617	1,332	0

Ts/Tv (transitions / transversions)

Transitions	21,983
Transversions	12,611
Ts/Tv ratio	1.7432

Wyniki te sugerują możliwe wspólne pochodzenie próbek „index” i „outbreak”, co jest zgodne z ich udziałem w ognisku epidemicznym, podczas gdy próbka „carriage” może reprezentować bardziej odległy wariant szczepu.

10. Wizualizację wariantów przeprowadzono w programie IGV. W wybranym regionie genomu zaobserwowano jedną z wielu wykrytych zmian nukleotydowych typu SNP widoczną w wielu odczytach, co potwierdza jej wiarygodność. Odczyty charakteryzowały się wysoką jakością mapowania oraz równomiernym pokryciem. Wariant był obecny we wszystkich analizowanych próbkach.

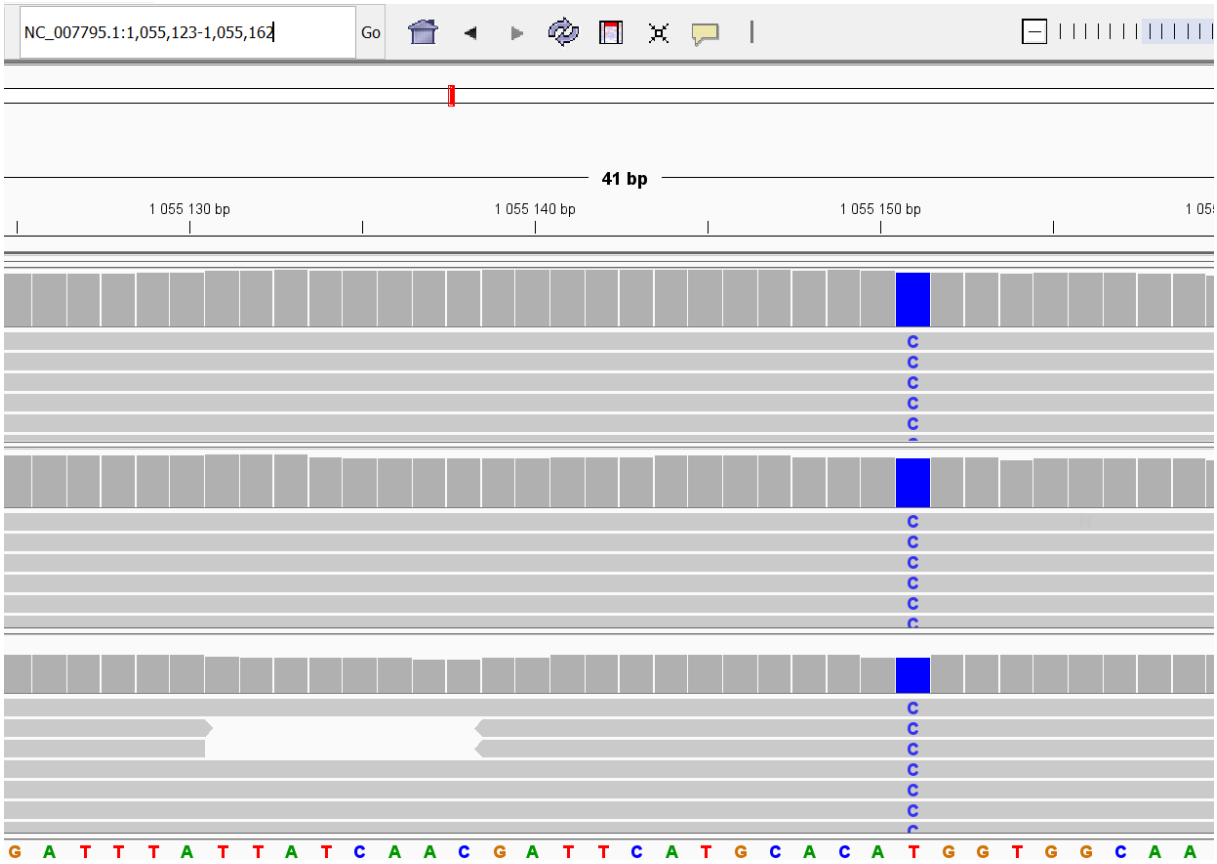

Wnioski: Uzyskane wyniki wskazują na wysokie podobieństwo genetyczne próbek „index” i „outbreak”, co sugeruje ich wspólne pochodzenie i potwierdza związek z ogniskiem epidemicznym.